NARAHOTEIS

DOCUMENTAÇÃO TÉCNICA DO PROJETO

Análise, tratamento e estruturação dos dados

AUTORES

Karoline Duffrayer

Daniel de Carvalho

SENAC RJ — Curso Analista de Dados – Big Data Science

Rio de Janeiro

2026

CONTROLE DO DOCUMENTO

Campo	Informação
Documento	NaraHoteis — Documentação Técnica do Projeto
Versão	1.0
Data	16/09/2026
Autores	Karoline Duffrayer e Daniel de Carvalho
Status	Em desenvolvimento
Base documental	Notebook de análise + scripts SQL de criação e consultas
Escopo desta versão	Tratamento de dados, Questões 01–04, banco MySQL e consultas SQL

Fonte: elaboração própria, com base nos arquivos do projeto.

Esta documentação tem caráter técnico e registra o estado do projeto conforme os arquivos efetivamente disponibilizados.

HISTÓRICO DE VERSÕES

Versão	Data	Responsáveis	Descrição
1.0	16/09/2026	Karoline Duffrayer; Daniel de Carvalho	Primeira versão da documentação técnica consolidando o notebook e os scripts SQL.

Fonte: elaboração própria, com base nos arquivos do projeto.

RESUMO EXECUTIVO

O projeto NaraHoteis apresenta um fluxo de trabalho de análise de dados que envolve a preparação de bases operacionais, auditoria da qualidade dos dados, tratamento de inconsistências, análise estatística e estruturação das informações em banco de dados relacional. A documentação desta versão foi elaborada exclusivamente com base no notebook de análise e tratamento e nos scripts SQL de criação e consulta enviados pelos autores.

No notebook foram trabalhadas seis bases: clientes, funcionários, canais de venda, tipos de quarto, unidades e reservas. O processo incluiu consolidação de lotes, identificação de valores ausentes e duplicados, padronização de campos categóricos, correção de valores inconsistentes, conversão de tipos e validação após o tratamento.

A etapa analítica atualmente documentada contempla quatro questões: comportamento das diárias e faturamento; operação acima da capacidade; identificação de desempenho de receita discrepante; e relação entre RevPAR e avaliação média dos hóspedes. Paralelamente, foi criado o banco narahoteis_db no MySQL, com seis tabelas relacionadas e dez consultas SQL para exploração dos dados.

Palavras-chave: análise de dados; qualidade de dados; Python; Pandas; MySQL; SQL; RevPAR; NaraHoteis.

SUMÁRIO

Para atualizar o sumário no Word: clique sobre ele com o botão direito e selecione “Atualizar campo”.

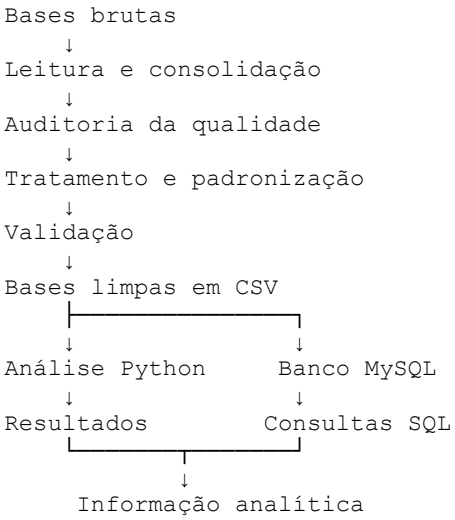
1 OBJETIVO E ESCOPO

O objetivo desta documentação é registrar, de forma estruturada e profissional, as atividades efetivamente implementadas no projeto NaraHoteis pelos autores Karoline Duffrayer e Daniel de Carvalho.

O escopo desta versão compreende o tratamento e a análise das bases em Python, as Questões 01 a 04 disponíveis no notebook, a criação e carga do banco de dados MySQL e as consultas SQL desenvolvidas. Etapas que não estão presentes nos arquivos analisados não são apresentadas como concluídas.

2 ARQUITETURA DO PROJETO

O fluxo técnico documentado nesta versão é:



3 BASES DE DADOS

Base	Finalidade no projeto
clientes	Informações cadastrais e características dos clientes.
funcionarios	Informações cadastrais e funcionais dos funcionários.
canais de venda	Canais utilizados para as reservas e respectivos percentuais de comissão.
tipos de quarto	Descrição, capacidade e valor da diária-base dos quartos.
unidades	Cadastro e características das unidades hoteleiras.
reservas	Registros transacionais utilizados nas análises de hospedagem.

Fonte: elaboração própria, com base nos arquivos do projeto.

4 AUDITORIA E TRATAMENTO DOS DADOS

A preparação dos dados foi realizada no notebook utilizando Pandas. A estratégia adotada foi primeiro inspecionar a estrutura das bases e identificar problemas, para somente

depois executar as correções. Foram utilizados recursos como shape, head, tail, info, dtypes, análise de valores ausentes, frequências e duplicidades.

4.1 Clientes

Os lotes de clientes foram consolidados. Foi identificado conflito envolvendo o identificador 47, e o registro de Carlos Neto recebeu o identificador 401. Os valores ausentes de faixa_etaria foram tratados como “Não informado”.

Também foram realizadas padronizações de cidades, estados e tipo de cliente. Variações de grafia e capitalização foram consolidadas, incluindo as representações de Pessoa Física e Pessoa Jurídica.

4.2 Funcionários

Os lotes de funcionários foram consolidados. O campo salario passou por limpeza, conversão para formato numérico e correção dos valores identificados como inconsistentes. Também foram padronizados cargos e departamentos e convertida data_admissao para formato de data.

ID	Valor corrigido
9	R$ 1.870,00
14	R$ 5.480,00
37	R$ 2.950,00
43	R$ 5.600,00
92	R$ 8.600,00
104	R$ 2.890,00
11	R$ 2.800,00
26	R$ 2.150,00

Fonte: elaboração própria, com base nos arquivos do projeto.

4.3 Canais de venda

Os nomes dos canais foram padronizados e o campo comissao_pct foi tratado para remoção do símbolo de porcentagem e conversão para formato numérico proporcional.

4.4 Tipos de quarto

Os lotes foram consolidados, as descrições foram padronizadas e duplicidades foram investigadas. O campo valor_diaria_base foi convertido para formato numérico após a limpeza dos valores monetários.

4.5 Unidades

Os lotes foram consolidados e o campo num_quartos_total foi tratado como variável numérica. Foram corrigidos os registros associados aos valores ausentes identificados no notebook, além da padronização de categorias de hotel e regiões.

4.6 Reservas

A base de reservas concentra as informações transacionais utilizadas nas análises. Foram tratados tipos de dados, quantidade de diárias, avaliação dos hóspedes, número de hóspedes, status da reserva, forma de pagamento, identificadores e duplicidades.

Na avaliação dos hóspedes, os valores inválidos 11 e -3 foram corrigidos, enquanto o valor 0 foi mantido. Foi criada a variável avaliado_sim_nao. O código 99 utilizado originalmente para indicar ausência de avaliação foi convertido para NaN na coluna numérica avaliacao_hospede. Dessa forma, ausência de avaliação permanece como valor ausente e não como uma nota.

Os status das reservas e as formas de pagamento também foram padronizados. Foram ainda verificadas duplicidades de id_reserva e valores inválidos de num_hospedes.

4.7 Exportação

As bases tratadas são exportadas em CSV com index=False e encoding='utf-8-sig'.

- clienteslimpo.csv
- funcionarioslimpo.csv
- canaislimpo.csv
- quartoslimpo.csv
- unidadeslimpo.csv
- reservaslimpo.csv

5 ANÁLISES REALIZADAS EM PYTHON

A versão atual do notebook documenta quatro questões analíticas. As análises utilizam agregações, medidas descritivas, identificação de outliers, cálculo de indicadores e correlação.

5.1 Questão 01 – Diárias e faturamento

Foram consideradas as reservas não canceladas. O faturamento estimado por reserva foi obtido pela multiplicação da quantidade de diárias pelo valor da diária-base do tipo de quarto.

```
faturamento = qtd_diarias * valor_diaria_base
```

Indicador	Resultado
Média	R$ 616,17
Mediana	R$ 580,00
Mínimo	R$ 280,00
Máximo	R$ 1.500,00
Q1	R$ 420,00
Q3	R$ 780,00

IQR	R$ 360,00
Amplitude	R$ 1.220,00
Assimetria	1,33
Limite superior	R$ 1.320,00

Fonte: elaboração própria, com base nos arquivos do projeto.

O valor de R$ 1.500,00 foi identificado como outlier superior pelo critério do IQR. O maior faturamento estimado registrado no período foi de R$ 777.300,00 para NaraHoteis Mangaratiba, enquanto o menor foi de R$ 269.880,00 para NaraHoteis Copacabana Premium.

Por se tratar de um cálculo baseado em quantidade de diárias e valor da diária-base, o indicador representa faturamento estimado, não necessariamente o valor efetivamente recebido.

5.2 Questão 02 – Capacidade das unidades

Foram consideradas reservas com status Confirmada ou Concluída. Para cada unidade e data, foi calculado o número de reservas ativas e comparado com a capacidade cadastrada. A condição de excesso foi definida por ocupação superior à capacidade.

Unidade	Capacidade	Pico de ocupação	Excesso	Ocupação máxima
NaraHoteis Centro	60	79	19	131,7%
NaraHoteis Nova Iguaçu Centro	50	64	14	128,0%
NaraHoteis Copacabana Premium	40	45	5	112,5%

Fonte: elaboração própria, com base nos arquivos do projeto.

Foram identificadas ocorrências acima da capacidade nas três unidades apresentadas. A interpretação operacional desse resultado deve considerar a possibilidade de overbooking, necessidade de realocação e pressão sobre a operação, sem concluir automaticamente que cada ocorrência representa um erro de cadastro.

5.3 Questão 03 – Desempenho de receita discrepante

Para permitir a comparação entre unidades de tamanhos diferentes, foi calculada a receita por quarto, obtida pela divisão da receita total pelo número de quartos. A média foi de R$ 9.664,59. Foi adotado o critério de diferença absoluta superior a 30% em relação à média para caracterizar desempenho discrepante.

Unidade	Receita total	Receita por quarto	Diferença
NaraHoteis Santa Teresa	R$ 676.720,00	R$ 15.038,22	+55,6%
NaraHoteis Mangaratiba	R$ 719.110,00	R$ 14.382,20	+48,8%
NaraHoteis Copacabana Premium	R$ 252.070,00	R$ 6.301,75	-34,8%
NaraHoteis Barra da Tijuca	R$ 656.340,00	R$ 5.469,50	-43,4%

Fonte: elaboração própria, com base nos arquivos do projeto.

A normalização por quantidade de quartos evita que o tamanho da unidade seja o único determinante da comparação. O resultado deve ser interpretado em conjunto com os demais indicadores de operação.

5.4 Questão 04 – RevPAR e avaliação

O RevPAR foi calculado por unidade relacionando a receita total ao número de quartos e ao período de observação. Em seguida, o indicador foi comparado à avaliação média dos hóspedes por meio de correlação de Pearson, heatmap e gráfico de dispersão.

Indicador	Resultado
Correlação de Pearson	0,41
Direção	Positiva
Interpretação registrada	Moderada

Fonte: elaboração própria, com base nos arquivos do projeto.

A correlação de 0,41 indica associação positiva moderada entre RevPAR e avaliação média no conjunto analisado. O resultado não estabelece causalidade e não deve ser interpretado isoladamente como evidência de capacidade preditiva.

6 BANCO DE DADOS MYSQL

O script SQL cria o banco narahoteis_db e estrutura seis tabelas: clientes, canais_venda, unidades, funcionarios, tipo_quartos e reservas.

```
CREATE DATABASE narahoteis_db;
USE narahoteis_db;
```

6.1 Estrutura relacional

Tabela	Chave primária	Relacionamentos principais
clientes	id_cliente	reservas.id_cliente
canais_venda	id_canal	reservas.id_canal
unidades	id_unidade	reservas.id_unidade; funcionarios.id_unidade
funcionarios	id_funcionario	id_unidade → unidades
tipo_quartos	id_tipo_quarto	reservas.id_tipo_quarto
reservas	id_reserva	Tabela transacional; referencia as demais tabelas

Fonte: elaboração própria, com base nos arquivos do projeto.

6.2 Chaves estrangeiras

- funcionarios.id_unidade → unidades.id_unidade
- reservas.id_unidade → unidades.id_unidade
- reservas.id_tipo_quarto → tipo_quartos.id_tipo_quarto
- reservas.id_cliente → clientes.id_cliente
- reservas.id_canal → canais_venda.id_canal

6.3 Carga dos dados

A carga das bases tratadas é realizada com LOAD DATA LOCAL INFILE. O script habilita local_infile e carrega os seis arquivos CSV nas respectivas tabelas. Os caminhos presentes no script são absolutos e correspondem à máquina utilizada durante o desenvolvimento; para execução em outro ambiente, devem ser ajustados.

7 CONSULTAS SQL

O arquivo de consultas contém dez consultas analíticas. Elas exploram os relacionamentos do banco utilizando JOIN, COUNT, AVG, WHERE, GROUP BY, HAVING e ORDER BY.

Nº	Pergunta / finalidade	Recursos SQL
1	Reservas por canal de venda	JOIN, COUNT, GROUP BY, ORDER BY
2	Reservas por tipo de cliente	JOIN, COUNT, GROUP BY, ORDER BY
3	Reservas por estado de origem	JOIN, COUNT, GROUP BY, ORDER BY
4	Reservas por canal e tipo de cliente	JOIN, COUNT, GROUP BY, ORDER BY
5	Reservas canceladas por canal	JOIN, WHERE, COUNT, GROUP BY
6	Reservas por unidade	JOIN, COUNT, GROUP BY, ORDER BY
7	Reservas por região	JOIN, COUNT, GROUP BY, ORDER BY
8	Média de avaliação por unidade	JOIN, AVG, WHERE, GROUP BY
9	Reservas por tipo de quarto	JOIN, COUNT, GROUP BY
10	Unidades com mais de 100 reservas	JOIN, COUNT, GROUP BY, HAVING

Fonte: elaboração própria, com base nos arquivos do projeto.

7.1 Exemplo – reservas por canal

```
SELECT
    c.nome_canal,
    COUNT(r.id_reserva) AS qtd_reservas
FROM reservas r
JOIN canais_venda c
    ON r.id_canal = c.id_canal
GROUP BY c.nome_canal
ORDER BY qtd_reservas DESC;
```

7.2 Exemplo – filtro com HAVING

```
SELECT
    u.nome_unidade,
    COUNT(r.id_reserva) AS qtd_reservas
FROM reservas r
JOIN unidades u
    ON r.id_unidade = u.id_unidade
GROUP BY u.nome_unidade
HAVING COUNT(r.id_reserva) > 100
```

```
ORDER BY qtd_reservas DESC;
```

8 QUALIDADE E LIMITAÇÕES DA ANÁLISE

O tratamento realizado reduz inconsistências presentes nas bases e estabelece regras explícitas para valores ausentes, categorias e identificadores. Entretanto, alguns indicadores dependem de premissas específicas do notebook e devem ser interpretados de acordo com essas regras.

- O faturamento das análises é estimado a partir de quantidade de diárias e valor da diária-base.
- O código 99 da base original representa ausência de avaliação e não uma nota.
- A comparação de receita entre unidades utiliza receita por quarto para reduzir o efeito do tamanho da unidade.
- O critério de discrepância de receita utilizado na análise é superior a 30% da média.
- A correlação de Pearson mede associação linear e não demonstra causalidade.
- Os caminhos de carga do MySQL dependem do ambiente local de execução.

9 ESTADO ATUAL E PRÓXIMAS ATUALIZAÇÕES

Esta versão da documentação registra as etapas efetivamente presentes nos arquivos analisados: tratamento das bases, Questões 01 a 04, estruturação do banco MySQL e dez consultas SQL.

O documento está em status Em desenvolvimento. Novas análises, modelos, dashboards ou outras entregas devem ser incorporados somente após sua implementação e validação nos arquivos oficiais do projeto.

10 CONCLUSÃO

O projeto apresenta uma cadeia de tratamento e análise que conecta a qualidade dos dados à exploração analítica e à organização das informações em banco relacional. A etapa de preparação foi estruturada para identificar e corrigir problemas antes da utilização dos dados nas análises, enquanto a etapa estatística utiliza os dados tratados para responder às questões atualmente implementadas no notebook.

A estrutura MySQL complementa o trabalho ao organizar as entidades em tabelas relacionadas e disponibilizar consultas SQL para exploração dos dados. A documentação

deverá acompanhar a evolução do projeto, mantendo separados os resultados já implementados das etapas ainda em desenvolvimento.

REFERÊNCIAS DOCUMENTAIS

DUFFRAYER, Karoline; CARVALHO, Daniel. nara_hoteis_tto_analise_dados_Q1_organizado(5).ipynb. 2026. Notebook de análise e tratamento de dados.

DUFFRAYER, Karoline; CARVALHO, Daniel. nara_hoteis_criacao(6).sql. 2026. Script SQL de criação e carga do banco de dados.

DUFFRAYER, Karoline; CARVALHO, Daniel. nara_hoteis_consulta(1).sql. 2026. Script SQL de consultas analíticas.

APÊNDICE A – MAPA DO BANCO DE DADOS

```
clientes (1) ———————— (N) reservas
canais_venda (1) ———————— (N) reservas
unidades (1) ———————— (N) reservas
tipo_quartos (1) ———————— (N) reservas
unidades (1) ———————— (N) funcionarios
```

APÊNDICE B – CRITÉRIOS ANALÍTICOS

Indicador	Critério / cálculo
Faturamento estimado	qtd_diarias × valor_diaria_base
Outlier de diária	Q3 + 1,5 × IQR
Excesso de capacidade	quartos ocupados > capacidade
Receita por quarto	receita total ÷ num_quartos_total
Discrepância de receita	diferença absoluta > 30% da média
RevPAR	receita total ÷ (quartos × dias observados)
Relação RevPAR × avaliação	correlação de Pearson

Fonte: elaboração própria, com base nos arquivos do projeto.